## Лабораторная работа №2. Реализация глубокой нейронной сети

- 1. Реализуйте полносвязную нейронную сеть с помощью библиотеки Tensor Flow. В качестве алгоритма оптимизации можно использовать, например, стохастический градиент (Stochastic Gradient Descent, SGD). Определите количество скрытых слоев от 1 до 5, количество нейронов в каждом из слоев до нескольких сотен, а также их функции активации (кусочно-линейная, сигмоидная, гиперболический тангенс и т.д.).
- 2. Как улучшилась точность классификатора по сравнению с логистической регрессией?
- 3. Используйте регуляризацию и метод сброса нейронов (dropout) для борьбы с переобучением. Как улучшилось качество классификации?
- 4. Воспользуйтесь динамически изменяемой скоростью обучения (learning rate). Наилучшая точность, достигнутая с помощью данной модели составляет 97.1%. Какую точность демонстрирует Ваша реализованная модель?

```
import os
try:
   import wget
except:
  !pip install wget
  import wget
import tarfile

out_dir = 'data/not_mnist'
small_arhive = f'{out_dir}/notMNIST_small.tar.gz'
large_arhive = f'{out_dir}/notMNIST_large.tar.gz'
large_url = 'https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz'
small_url = 'https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz'
```

Collecting wget

```
Downloading https://files.pythonhosted.org/packages/47/6a/62e288da7bcda82b935ff0c6cfe542970f04e29c756b0e147251b2fb2!
     Building wheels for collected packages: wget
      Building wheel for wget (setup.py) ... done
      Created wheel for wget: filename=wget-3.2-cp36-none-any.whl size=9682 sha256=50e0f3f3d45a0ce8bfeec8caf1f9529fa273e4
      Stored in directory: /root/.cache/pip/wheels/40/15/30/7d8f7cea2902b4db79e3fea550d7d7b85ecb27ef992b618f3f
    Successfully built wget
     Installing collected packages: wget
     Successfully installed wget-3.2
if not os.path.exists(out dir):
  os.makedirs(out dir)
if not os.path.exists(small arhive):
  print(f"Downloading {small arhive}.")
  wget.download(small url, small arhive)
  print()
else:
  print(f"Skipping {small arhive} download (already exists)")
if not os.path.exists(large arhive):
  print(f"Downloading {large arhive}.")
  wget.download(large url, large arhive)
  print()
else:
  print(f"Skipping {large arhive} download (already exists)")
    Downloading data/not mnist/notMNIST small.tar.gz.
    Downloading data/not mnist/notMNIST large.tar.gz.
print(f"Extracting {small arhive}")
with tarfile.open(small arhive) as tar:
  tar.extractall(out dir)
print(f"Extracting {large arhive}")
```

```
with tarfile.open(large arhive) as tar:
  tar.extractall(out dir)
Extracting data/not mnist/notMNIST small.tar.gz
    Extracting data/not mnist/notMNIST large.tar.gz
import numpy as np
from pathlib import Path
from PIL import Image
def remove duplicates(img train, labels train, img test):
    img new, labels new = [], []
    test set = {e.tostring() for e in img test}
    for i, (x, y) in enumerate(zip(img train, labels train)):
        if x.tostring() not in test set:
            img new.append(x)
            labels new.append(y)
    print(f'Removed {img train.shape[0] - len(img new)} duplicated images')
    return np.array(img new), np.array(labels new)
def load images(path, n):
    labels = ['I', 'G', 'A', 'F', 'H', 'J', 'C', 'D', 'E', 'B']
    x, y = [], []
    for i, l in enumerate(labels):
        d = Path(path) / 1
        print(f'Loading {str(d)} ', end='')
        for j, f in zip(range(n), d.iterdir()):
            try:
                with Image.open(f) as img:
                    x.append(np.array(img))
                    y.append(i)
            except OSError:
                pass
            if j % 1000 == 0:
                print('.', end='', flush=True)
        print(flush=True)
```

```
return np.array(labels), np.array(x), np.array(y)
def load not mnist data(path='data/not mnist/', use cache=True):
   train folder = Path(path) / 'notMNIST large'
   test folder = Path(path) / 'notMNIST small'
   train cache file = Path(path) / 'train.npz'
   test cache file = Path(path) / 'test.npz'
    if train cache file.exists() and test cache file.exists() and use cache:
        f = np.load(train cache file)
        labels, img train, labels train = [v for k, v in f.items()]
        f = np.load(test cache file)
        labels, img test, labels test = [v for k, v in f.items()]
        print('Loaded cached arrays')
    else:
        labels, img train, labels train = load images(train folder, 10000000)
        labels, img test, labels test = load images(test folder, 10000000)
        np.savez(train cache file, labels, img train, labels train)
        np.savez(test cache file, labels, img test, labels test)
    return labels, img train, labels train, img test, labels test
labels, img train, labels train, img test, labels test = load not mnist data()
   Loaded cached arrays
img train, labels train = remove duplicates(img train, labels train, img test)
    Removed 12213 duplicated images
from sklearn.linear model import SGDClassifier, LogisticRegression
from sklearn.model selection import train test split
def flatten(a):
    return a rechanela chanel() a chanel() * a chanel() )
```

https://colab.research.google.com/drive/186rLyq6W-MHkjvtuR4qCnzw-7xMgDt8F#scrollTo=D7IFZJSBn7JH&printMode=true

```
def load_data():
    labels, img_train, labels_train, img_test, labels_train, labels_train, img_test)
    return labels, flatten(img_train), labels_train, flatten(img_test), labels_test

labels, img_train, labels_train, img_test, labels_train, flatten(img_test), labels_test

labels, img_train, labels_train, img_test, labels_test = load_not_mnist_data()
img_train, labels_train = remove_duplicates(img_train, labels_train, img_test)
Loaded cached arrays
```

**Задание 1.** Реализуйте полносвязную нейронную сеть с помощью библиотеки Tensor Flow. В качестве алгоритма оптимизации можно использовать, например, стохастический градиент (Stochastic Gradient Descent, SGD). Определите количество скрытых слоев от 1 до 5, количество нейронов в каждом из слоев до нескольких сотен, а также их функции активации (кусочно-линейная, сигмоидная, гиперболический тангенс и т.д.).

```
import tensorflow as tf
from tensorflow.keras import datasets, layers, models
from keras.callbacks import EarlyStopping

results = {}
results.setdefault('val_acc', {})

model = tf.keras.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(200, activation='relu'),
    tf.keras.layers.Dense(200, activation='relu'),
    tf.keras.layers.Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
    loss='sparse_categorical_crossentropy',
```

Removed 12213 duplicated images

C→

```
Epoch 1/100
Epoch 2/100
Epoch 3/100
Epoch 4/100
Epoch 5/100
Epoch 6/100
Epoch 7/100
Epoch 8/100
Epoch 9/100
Epoch 10/100
Epoch 11/100
Epoch 12/100
Epoch 13/100
Epoch 14/100
Epoch 15/100
Epoch 16/100
Epoch 17/100
Epoch 18/100
Epoch 19/100
Epoch 20/100
Epoch 21/100
```

```
Epoch 22/100
Epoch 23/100
Epoch 24/100
Epoch 25/100
Epoch 26/100
Epoch 27/100
Epoch 28/100
Epoch 29/100
Epoch 30/100
Epoch 31/100
Epoch 32/100
Epoch 33/100
Epoch 34/100
Epoch 35/100
Epoch 36/100
Epoch 37/100
Epoch 38/100
Epoch 39/100
# Evaluate
[0.27337297797203064, 0.9323328137397766]
```

Задание 2. Как улучшилась точность классификатора по сравнению с логистической регрессией?

Точность классификатора повысилась на 11 процентов

**Задание 3.** Используйте регуляризацию и метод сброса нейронов (dropout) для борьбы с переобучением. Как улучшилось качество классификации?

В моей модели качество классификации не улучшилось при добавлении, скорее всего штраф был большим, и отбрасывались веса, которые могли бы описать удачнее модель, пытался уменьшать штраф, так как результат был еще меньше чем без регуляризации

```
initializer = tf.keras.initializers.TruncatedNormal(mean=0.0, stddev=0.05, seed=None)
regL1 = tf.keras.regularizers.l1(0.0001)
regL2 = tf.keras.regularizers.12(0.0001)
model2 = tf.keras.Sequential([
    tf.keras.layers.Flatten(input shape=(28, 28)),
    tf.keras.layers.Dense(200,
                          activation='relu',
                          kernel regularizer=regL2,
                          bias regularizer=regL2,
                          bias initializer=initializer,
                          kernel initializer=initializer),
    tf.keras.layers.Dense(200,
                          activation='relu',
                          kernel regularizer=regL2,
                          bias regularizer=regL2,
                          bias initializer=initializer,
                          kernel initializer=initializer),
    tf.keras.layers.Dense(10, activation='softmax')
])
model2.compile(optimizer='adam',
              loss='sparse categorical crossentropy',
              metrics=['accuracy'])
#steps per epoch=tf.math.ceil(train size/BATCH SIZE).numpy()
#model.fit(train dataset, epochs=10, steps per epoch=steps per epoch, validation data=(test dataset))
```

```
Epoch 1/100
Epoch 2/100
Epoch 3/100
Epoch 4/100
Epoch 5/100
Epoch 6/100
Epoch 7/100
Epoch 8/100
Epoch 9/100
Epoch 10/100
Epoch 11/100
Epoch 12/100
Epoch 13/100
Epoch 14/100
Epoch 15/100
Epoch 16/100
# Evaluate
[0.3239336907863617, 0.9172185659408569]
```

```
tf.keras.layers.Dense(200,
                          activation='relu',
                          kernel regularizer=regL2,
                          bias regularizer=regL2,
                          bias initializer=initializer,
                          kernel initializer=initializer),
    tf.keras.layers.Dropout(0.1),
    tf.keras.layers.Dense(200,
                          activation='relu',
                          kernel regularizer=regL2,
                          bias regularizer=regL2,
                          bias initializer=initializer,
                          kernel initializer=initializer),
    tf.keras.layers.Dropout(0.1),
    tf.keras.layers.Dense(10, activation='softmax')
])
model3.compile(optimizer='adam',
              loss='sparse categorical crossentropy',
             metrics=['accuracy'])
#steps per epoch=tf.math.ceil(train size/BATCH SIZE).numpy()
#model.fit(train dataset, epochs=10, steps per epoch=steps per epoch, validation data=(test dataset))
model3.fit(x=img train, y=labels train, epochs=100,
          callbacks=[callback], validation split=0.1)
#model.fit(train dataset, epochs=2, steps per epoch=steps per epoch)
print('\n# Evaluate')
result = model3.evaluate(img_test, labels_test)
print (result)
С→
```

```
Epoch 1/100
Epoch 2/100
Epoch 3/100
Epoch 4/100
Epoch 5/100
Epoch 6/100
Epoch 7/100
Epoch 8/100
Epoch 9/100
Epoch 10/100
Epoch 11/100
Epoch 12/100
Epoch 13/100
Epoch 14/100
Epoch 15/100
Epoch 16/100
Epoch 17/100
Epoch 18/100
Epoch 19/100
Epoch 20/100
Epoch 21/100
```

```
Epoch 22/100
Epoch 23/100
Epoch 24/100
Epoch 25/100
Epoch 26/100
Epoch 27/100
Epoch 28/100
Epoch 29/100
Epoch 30/100
Epoch 31/100
Epoch 32/100
Epoch 33/100
Epoch 34/100
Epoch 35/100
# Evaluate
[0.28747716546058655, 0.9201025366783142]
```

**Задание 4.** Воспользуйтесь динамически изменяемой скоростью обучения (learning rate). Наилучшая точность, достигнутая с помощью данной модели составляет 97.1%. Какую точность демонстрирует Ваша реализованная модель?

Сравнение алгоритма без динамического шага, все предыдущие были с оптимизатором adam

```
model4 = tf.keras.Sequential([
```

С→

```
tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(300, activation='relu'),
    tf.keras.layers.Dense(300, activation='relu'),
    tf.keras.layers.Dense(300, activation='relu'),
    tf.keras.layers.Dense(10, activation='softmax')
1)
learning rate = 0.001
optimizer = tf.compat.v1.train.GradientDescentOptimizer(learning rate)
model4.compile(optimizer=optimizer,
              loss='sparse categorical crossentropy',
              metrics=['accuracy'])
#steps per epoch=tf.math.ceil(train size/BATCH SIZE).numpy()
#model.fit(train dataset, epochs=10, steps per epoch=steps per epoch, validation data=(test dataset))
model4.fit(x=img train, y=labels train, epochs=100,
          callbacks=[callback], validation split=0.1)
#model.fit(train dataset, epochs=2, steps per epoch=steps per epoch)
print('\n# Evaluate')
result = model4.evaluate(img test, labels test)
print (result)
```

```
Epoch 1/100
Epoch 2/100
Epoch 3/100
Epoch 4/100
Epoch 5/100
Epoch 6/100
Epoch 7/100
Epoch 8/100
Epoch 9/100
Epoch 10/100
Epoch 11/100
Epoch 12/100
Epoch 13/100
Epoch 14/100
Epoch 15/100
Epoch 16/100
Epoch 17/100
Epoch 18/100
Epoch 19/100
Epoch 20/100
Epoch 21/100
```

```
Epoch 22/100
Epoch 23/100
Epoch 24/100
Epoch 25/100
Epoch 26/100
Epoch 27/100
Epoch 28/100
Epoch 29/100
Epoch 30/100
Epoch 31/100
Epoch 32/100
Epoch 33/100
Epoch 34/100
Epoch 35/100
Epoch 36/100
Epoch 37/100
Epoch 38/100
Epoch 39/100
Epoch 40/100
Epoch 41/100
Epoch 42/100
14538/14538 [=======
    ========== ] - 71s 5ms/step - loss: 0.1744 - accuracy: 0.9434 - val loss: 3.0271 - val
```

```
Epoch 43/100
Epoch 44/100
Epoch 45/100
Epoch 46/100
Epoch 47/100
Epoch 48/100
Epoch 49/100
Epoch 50/100
Epoch 51/100
Epoch 52/100
Epoch 53/100
Epoch 54/100
Epoch 55/100
Epoch 56/100
Epoch 57/100
Epoch 58/100
Epoch 59/100
Epoch 60/100
Epoch 61/100
Epoch 62/100
Epoch 63/100
14538/14538 [======
    ========= ] - 71s 5ms/step - loss: 0.1336 - accuracy: 0.9562 - val loss: 3.5179 - val
Epoch 64/100
```

```
Thoon oalton
Epoch 65/100
Epoch 66/100
Epoch 67/100
Epoch 68/100
Epoch 69/100
Epoch 70/100
Epoch 71/100
Epoch 72/100
Epoch 73/100
Epoch 74/100
Epoch 75/100
Epoch 76/100
Epoch 77/100
Epoch 78/100
Epoch 79/100
Epoch 80/100
Epoch 81/100
Epoch 82/100
Epoch 83/100
Epoch 84/100
Epoch 85/100
```

```
Epoch 86/100
Epoch 87/100
Epoch 88/100
Epoch 89/100
Epoch 90/100
Epoch 91/100
Epoch 92/100
Epoch 93/100
Epoch 94/100
Epoch 95/100
Epoch 96/100
Epoch 97/100
Epoch 98/100
Epoch 99/100
Epoch 100/100
# Evaluate
[0.6749985814094543, 0.9272057414054871]
```